

סיכום תיאורטי: קשר שגיאה-שארית, חסמים והתניה מראש

PINNs (Preconditioning) ב-PINNs

מסמך זה מאגד את התשתית המתמטית והפיזיקלית להבנת כשלי ההתכנסות של רשתות ניורונים פיזיקליות (PINNs) במשוואות היפרבוליות, ואת ההצדקה לשימוש בצפיפות קווים אופייניים ככלי לתיקון כשלים אלו.

1. הגדרות בסיס: שארית (R) מול שגיאה (e)

נתבונן במשוואה דיפרנציאלית חלקית המיוצגת על ידי אופרטור ליניארי (או ליניאריזציה מקומית) L . הפתרון האמיתי והמדויק של המערכת, u^* , מקיים:

$$L[u^*] = 0$$

רשת הניורונים שלנו מספקת פתרון מקורב u_θ . אנו מגדירים שני גדלים קריטיים:

1. השגיאה האמיתית (e): המרחק בין תחזית הרשת לפתרון האמיתי:

$$e = u_\theta - u^*$$

2. השארית (R): המידה שבה הפתרון המקורב אינו מקיים את המשוואה:

$$R = L[u_\theta]$$

הקשר המתמטי: מכיוון שהאופרטור L ליניארי (או מתנהג כליניארי בקירוב לפתרון), מתקיים:

$$L[e] = L[u_\theta - u^*] = L[u_\theta] - L[u^*] = R - 0 = R$$

מכאן נובע הקשר היסודי המחבר בין מה שהרשת רואה לבין השגיאה בפועל:

$$e = L^{-1}[R]$$

כאשר L^{-1} הוא האופרטור ההופכי.

2. החסם על נורמת השגיאה (The Error Bound)

באנליזה פונקציונלית, אנו לוקחים נורמה של שני אגפי המשוואה כדי לחסום את השגיאה:

$$\|e\| \leq \|L^{-1}\| \cdot \|R\|$$

- $\|R\|$ הוא הגודל שאותו האופטימיזטור (Adam/L-BFGS) ממזער באופן פעיל (פונקציית ה-Loss).
- $\|L^{-1}\|$ הוא **קבוע היציבות** (Stability Constant) של האופרטור. הוא מוגדר כ:

$$\|L^{-1}\| = \sup_{e \neq 0} \frac{\|e\|}{\|L[e]\|}$$

הכשל הנומרי (The PINN Illusion): האופטימיזטור עוצר כאשר השארית מגיעה לרצפת הרעש הנומר כלומר $\epsilon \rightarrow \|R\|$. עם זאת, במשוואות היפרבוליות עם גלי הלם (Shocks), האופרטור L הוא בעל קבון יציבות $\|L^{-1}\|$ ענקי (או שואף לאינסוף בגבול הבלתי צמיג). המשמעות היא שקיימים "אופני שגיאה" (Error modes) – למשל, הזזה קלה של חזית ההלם – המייצרים שגיאה ענקית $\|e\|$, אך כמעט ולא מייצרים שארית $\|L[e]\|$. לכן, גם כשהאופטימיזטור מצליח לאפס את השארית ($\|R\| \approx \epsilon$), החסם העליון על השגיאה $\|e\| \leq \infty \cdot \epsilon$ נותר משוחרר, והרשת יכולה להתכנס לפתרון שגוי ("מרוח") לחלוטי

3. עדכון הקשר באמצעות פונקציית משקל שרירותית $q(x, t)$

כדי לטפל בכשל זה, נציע להכפיל את משוואת השארית בפונקציית משקל כלשהי $q(x, t) > 0$. מתמטית, משמעות הדבר היא הגדרת **אופרטור חדש**, $\tilde{L} = qL$. השארית החדשה שהאופטימיזטור רואה היא:

$$\tilde{R} = qR = qL[u_\theta]$$

הקשר החדש בין השגיאה לשארית הוא $\tilde{L}[e] = \tilde{R}$, ומכאן החסם החדש:

$$\|e\| \leq \|(qL)^{-1}\| \cdot \|qR\|$$

הדינמיקה מול האופטימיזטור: בהינתן אופטימיזטור חזק (כמו L-BFGS), הוא שוב ימזער את פונקציית המטרה החדשה עד לרצפת הרעש: $\epsilon \rightarrow \|qR\|$. לכן, החסם החדש ברגע העצירה של הרשת יהיה:

$$\|e\| \leq \|(qL)^{-1}\| \cdot \epsilon$$

4. מדוע צפיפות האופיינים כ- q מבטיחה שיפור?

כאן נכנסת הפיזיקה לתמונה. אנו בוחרים את $q(x, t)$ להיות צפיפות הקווים האופייניים של המערכת ההיפרבולית.

נזכור את הגדרת הנורמה ההופכית של האופרטור הממושקל:

$$\|(qL)^{-1}\| = \sup_{e \neq 0} \frac{\|e\|}{\|q \cdot L[e]\|}$$

הסופרמום מונע מאותם אופני שגיאה "גרועים" (e_{worst}) שבהם המכנה קטן ביחס למונה. במשוואות היפרבוליות, שגיאות אלו מתרכזות אך ורק באזורי ההלם. מתוך הקינמטיקה של משוואת הרציפות, אנ יודעים כי צפיפות האופייניים $q(x, t)$ שואפת לערכי מקסימום אדירים בדיוק באותם אזורי הלם.

לכן, עבור אותן שגיאות קריטיות:

1. השארית המקורית $\|L[e_{worst}]\|$ הייתה זעירה.
 2. כעת, שארית זו מוכפלת מקומית בפונקציה q שהיא עצומה בדיוק באותו תא מרחבי.
 3. המכנה החדש, $\|q \cdot L[e_{worst}]\|$, גדל משמעותית.
 4. מכיוון שהמכנה גדל היכן שקודם היה קטן, ערך הסופרמום הכולל חייב לרדת.
- לפיכך, בהכרח מתקיים התנאי המהדק את תקרת השגיאה:

$$\|(qL)^{-1}\| \ll \|L^{-1}\|$$

5. מתיאוריה לפרקטיקה: ההכרח בדגימת חשיבות (Importance Sampling)

אם ניישם את המשוואה $\int q |R|^2 dx dt$ כפשוטה (הכפלת ה-Loss המקומי בקבוע ענק q), ניצור בעיה קשיחה (ill-conditioned) שעבורה מטריצת ההסיאן מתפוצצת, ואופטימיזטור ה-L-BFGS ייכשל.

הפתרון האלגנטי הוא דגימת חשיבות (Importance Sampling). במקום למזער אינטגרל ממושקל על רשת אחידה, אנו דוגמים את נקודות הקולוקציה x_i ישירות מתוך התפלגות הצפיפות $q(x, t)$, וממזער פונקציית Loss רגילה (Vanilla):

$$\frac{1}{N} \sum_{x_i \sim q(x, t)} |R(x_i, t_i)|^2 \xrightarrow{N \rightarrow \infty} \int_{\Omega} q(x, t) |R(x, t)|^2 dx dt$$

גישה זו שומרת על החסם ההדוק והמשופר $\|(qL)^{-1}\|$, אך שומרת על מטריצת הסיאן בעלת מספר מצב קטן ויציב, המאפשר התכנסות נוחה של L-BFGS.

6. תחימת השגיאה משני הכיוונים: החסם התחתון ומספר המצב

עד כה דיברנו על התקרה (החסם העליון). אך באנליזה פונקציונלית, ניתן לחסום את השגיאה גם מלמנ מתוך הגדרת נורמת האופרטור (המידה המקסימלית שבה האופרטור מנפח פונקציה), מתקיים:

$$\|R\| = \|L[e]\| \leq \|L\| \cdot \|e\|$$

מכאן נגזר החסם התחתון:

$$\|e\| \geq \frac{1}{\|L\|} \|R\|$$

אם נשלב את שני החסמים, נקבל ששגיאת הרשת "כלואה" באי-שוויון כפול:

$$\frac{1}{\|L\|} \|R\| \leq \|e\| \leq \|L^{-1}\| \|R\|$$

ההשפעה של משקולת q על החסם התחתון

כאשר עברנו לאופרטור החדש qL , החסם התחתון הפך ל- $\frac{1}{\|qL\|}$. האופרטור qL כופל את המערכת בערכים עצומים באזור ההלם. לפיכך, היכולת של qL "לנפח" שגיאה גדולה הרבה יותר מהיכולת של L לבדו. מתמטית, מתקיים $\|qL\| > \|L\|$. כתוצאה מכך, המכנה גדל והחסם התחתון קטן:

$$\frac{1}{\|qL\|} < \frac{1}{\|L\|}$$

האם ירידת החסם התחתון היא בעיה? להפך! החסם התחתון מייצג את "הרצפה" של השגיאה (השגי המינימלית האפשרית עבור שארית נתונה). כאשר הרצפה יורדת, היא פותחת לשגיאה $\|e\|$ את הדלת לשאוף קרוב יותר לאפס המוחלט כאשר האופטימיזטור מקטין את ה-Loss (השארית) לרצפת הרעש :

מספר המצב (Condition Number)

היחס בין החסם העליון לתחתון מוגדר כמספר המצב של המערכת:

$$\kappa(L) = \|L\| \cdot \|L^{-1}\|$$

במערכות היפרבוליות, $\kappa \rightarrow \infty$, ולכן השארית איננה אינדיקטור אמין לשגיאה. היתרון העצום של Importance Sampling הוא שאנו מכוונים אל אופרטור ממושקל שבו $\|(qL)^{-1}\|$ קטן באופן דרמטי מ-

$\|L^{-1}\|$, מה שגורם להידוק משמעותי של החסם ושיפור הייצוגיות של פונקציית המחיר.

7. חישוב אנליטי ונומרי של נורמות האופרטורים L ו- L^{-1}

האם ניתן לחשב את הגדלים הללו בפועל כדי להוכיח שאכן הקטנו את התקרה? כן, קיימות שתי דרכים מרכזיות לכך.

א. הגישה האנליטית (Fourier / von Neumann Analysis)

עבור אופרטורים ליניאריים בעלי מקדמים קבועים (או בקירוב של מקדמים קפואים - Frozen Coefficients מקומיים), ניתן להשתמש בהתמרת פורייה כדי לעבור למרחב התדר. האופרטור הדיפרנציאלי L הופך ל"סמל" (Symbol) אלגברי $\hat{L}(k)$, התלוי במספר הגל k .

- **נורמת האופרטור $\|L\|$** קשורה לסופרמום של $|\hat{L}(k)|$ על פני כל התדרים. במשוואות הכוללות גזרות גבוהות (כמו צמיגות $\nu \partial_{xx}$), התדרים הגבוהים ינפחו את הסמל.
- **נורמת האופרטור ההופכי $\|L^{-1}\|$** קשורה לסופרמום של $|1/\hat{L}(k)|$, או במילים אחרות, להופכי האינפימום של $|\hat{L}(k)|$. במשוואות היפרבוליות, סביב גלי ההלם (כאשר הצמיגות $\nu \rightarrow 0$), האינפימום הזה שואף לאפס עבור תדרים מסוימים, מה שמוכיח אנליטית ש- $\|L^{-1}\| \rightarrow \infty$.

ב. הגישה הנומרית (Matrix SVD)

כדי לחשב את הנורמות בפועל לבעיה ספציפית ומורכבת, עוברים לאלגברה ליניארית:

1. בונים רשת מרחבית-זמנית דיסקרטית (Grid).
2. הופכים את האופרטור הדיפרנציאלי הליניארי (הליניאריזציה $N'[u^*]$) למטריצה ספֶרֶסִית אדירה. באמצעות הפרשים סופיים (FDM).
3. נורמות האופרטור מתורגמות לערכים הסינגולריים של המטריצה A (מתוך פירוק SVD):

$$\|L\| \approx \sigma_{\max}(A)$$

$$\|L^{-1}\| \approx \frac{1}{\sigma_{\min}(A)}$$

הוכחת ה-Preconditioning נומרית: ניתן להגדיר מטריצה אלכסונית Q שעל האלכסון שלה יושבים הערכים של $q(x_i, t_i)$. כעת, בונים את המטריצה החדשה $\tilde{A} = QA$. חישוב נומרי פשוט בפיתון (למ בעזרת `scipy.linalg.svd`) יראה בבירור ש:

$$\frac{1}{\sigma_{\min}(QA)} \ll \frac{1}{\sigma_{\min}(A)}$$

פעולה זו מוכיחה באופן מובהק שהכפלת המערכת בצפיפות האופייניים ייצבה את האופרטור ההופכי וסגרה את הפער למזעור שגיאת החיזוי.

